עיבוד ספרתי של תמונות: תרגיל בית 1

מגישים:
שלמה עזרא 205359938
יונתן גולן 208980888

חלק א': הקוד לחלק זה נמצא תחת הקובץ "Ex1" שבתיקייה 1(בנוסף מצורף כנספח 1).
1. אינטרפולציה:
a. כתבנו פונקציה "interpolation " אשר מבצעת bilinear interpolation (מגודל nxm ל – 2nx2m).

b. טענו את התמונה peppers.jpg והגדלנו אותה בפקטור 2 בעזרת הפונקציה שקיבלנו.

התוצאה שקיבלנו:

ניתן לראות כי התוצאה מטושטשת יותר מהתמונה המקורית מכיוון שבאינטרפולציה הגדלנו את התמונה פי 2 ואנו עושים ממוצע של הפיקסלים מהתמונה המקורית כדי להשלים את הפיקסלים שלא היו קיימים לנו, כתוצאה מהממוצע הזה נוצר לנו טשטוש.

את התוצאה שמרנו כנדרש בתיקייה של חלק 1 תחת השם "Peppers_interpolated_by_2".

c. חזרנו על הסעיף הקודם והגדלנו בפקטור 8 (מתקבל ע"י הגדלת התמונה המקורית 3 פעמים בפקטור 2 או לחלופין הגדלת התמונה שקיבלנו בסעיף הקודם פעמיים נוספות בפקטור 2 – כך הקוד עצמו יעיל יותר..).

התוצאה שקיבלנו:

בדומה לסעיף הקודם קיבלנו תמונה מטושטשת וגדולה יותר.

את התוצאה שמרנו כנדרש בתיקייה של חלק 1 תחת השם "Peppers_interpolated_by_8".

השוואה בין התוצאות של סעיפים c-b :

ניתן לראות כי בשני הסעיפים קיבלנו תמונה גדולות יותר ומטושטשות יותר מהתמונה המקורית,
כאשר בסעיף c קיבלנו תמונה גדולה יותר ומטושטשת יותר מהתמונה מסעיף b.
באופן כללי ככל שאנו מבצעים אינטרפולציה גדולה יותר אנו נדרשים להשלים יותר פיקסלים ולכן אנו מקבלים תמונה גדולה יותר אך מטושטשת יותר.

2. שיווי היסטוגרמה:

a. חישבנו את ההיסטוגרמה של התמונה – leafs.jpg באמצעות הפונקציה " plot_hist " – אשר מחשבת את ההיסטוגרמה של התמונה, מציגה ושומרת אותה.

ההיסטוגרמה שקיבלנו לתמונה:

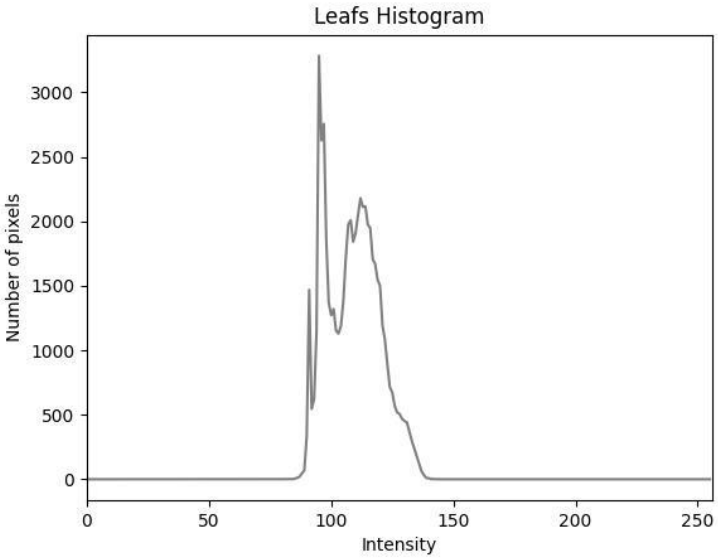

ניתן לראות את מספר הפיקסלים שיש לנו בכל רמת בהירות.

בנוסף הערכים של הפיקסלים מרוכזים בערך בטווח 90-140 , כך שיש לנו ניגודיות יחסית נמוכה.

b.מתיחת קונטרסט – כתבנו את הפונקציה "stretch_contrast " בה חישבנו לכל פיקסל In את הערך:

$$Out = 255 * \frac{In - f_{min}}{f_{max} - f_{min}}$$

מכיוון שקיבלנו ערכים לא שלמים עיגלנו את התוצאה.

התמונה אשר קיבלנו:

מתיחת הקונטרסט אפשרה לנו להעלות את הקונטרסט בתמונה כך שהפריטים בתמונה מעט ברורים יותר, כך למעשה הגדלנו את טווח הערכים של הפיקסלים בתמונה.

ההיסטוגרמה של התמונה:

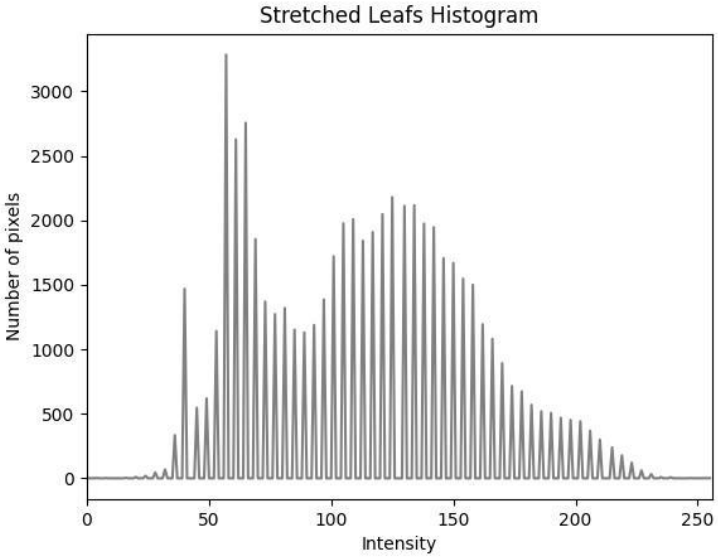

ניתן לראות כי לעומת טווח הערכים המקורי של התמונה אשר היה מצומצם (בערך בטווח -90 140)
קיבלנו כעת טווח הערכים רחב של 0 עד 255.

c.שיווי היסטוגרמה – ממישנו את הפונקציה "equalize_hist " אשר מבצעת שיווי היסטוגרמה לתמונה.

התמונה שקיבלנו:

לאחר שביצענו שיווי היסטוגרמה אנו יכולים לראות את הפרטים בתמונה באופן טוב יותר (מכיוון שיש לנו הרבה יותר קונטרסט בתמונה) אולם נוסף לנו הרבה רעש שלא היה קיים בתמונה המקורית.

ההיסטוגרמה של התמונה שקיבלנו:

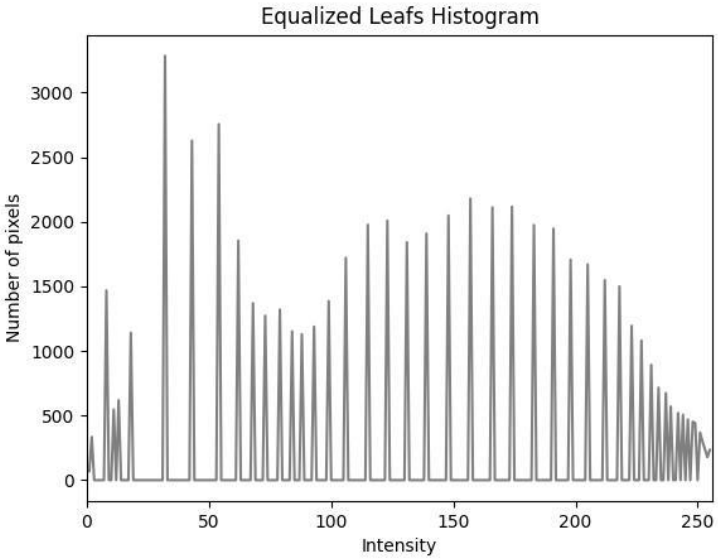

ההיסטוגרמה כעת לאחר שיווי היסטוגרמה מתפלגת באופן יוניפורמי יותר. בנוסף ניתן לראות כי הקונטרסט בתמונה משתפר (מקבלים יותר פיקסלים ברמות הבהירות בקצה- הטווח נהיה רחב יותר והקונטרסט משתפר מהסעיף הקודם).

חלק ב': הקוד לחלק זה נמצא תחת הקובץ "Ex2" שבתיקייה 2(בנוסף מצורף כנספח 2).

1. המימוש נמצא בקוד המצורף לפרויקט.
2.

a. מימשנו מסנן גזירה והפעלנו מסנן גזירה על l.jpg

מסנן גזירה על l_n.jpg:

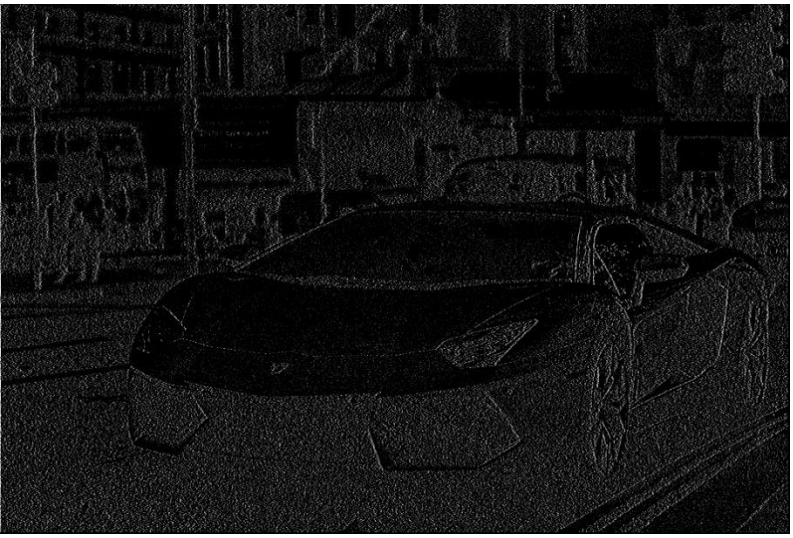

ניתן לראות בתמונה הנקיה כי המסנן הגוזר מתמקד בשינויים אנכיים בתמונה, ולכן הקווים הבולטים הינם אנכיים. בתמונה הרועשת המסנן הגוזר מקבל המון רעש שהוא גם אנכי ולכן ניתן לראות את התמונה המקורית היטב בו.

b. מסנן גאוסיאני

ניתן לראות כי הנקודות הרועשות נמרחו בעזרת ההחלקה והטשטוש שהגאוסיין עושה. אמנם הרעש שופר אך בכללי התמונה אינה נראית טובה יותר ממקודם.

c. מסנן Sobel

גם פה ניתן לראות שהרעש מאוד משפיע על המסנן וכי הוא לא מנקה אותו. (ניתן היה להגדיר את התמונה בגווני אפור אך רצינו להראות כי עם רעש כמו בתמונה קשה למסנן סובל להתמודד)

כמובן שעל הרקע הלבן של המכונית הרעש פחות משמעותי, בעוד במקומות בהם התמונה היתה אמורה להיות כהה הרעש בולט.

.3

a. חישבנו את התמרת הפורייה של שתי התמונות וקיבלנו את האמפליטודה והפאזה הבאות של ההתמרות:

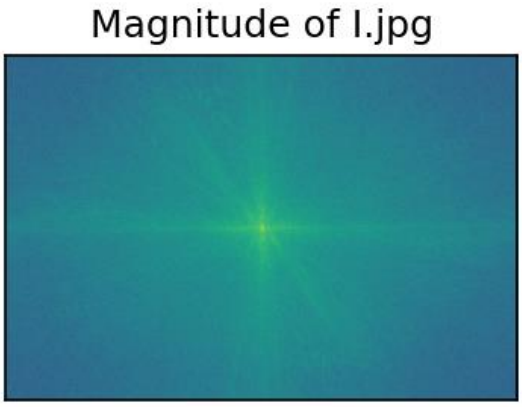

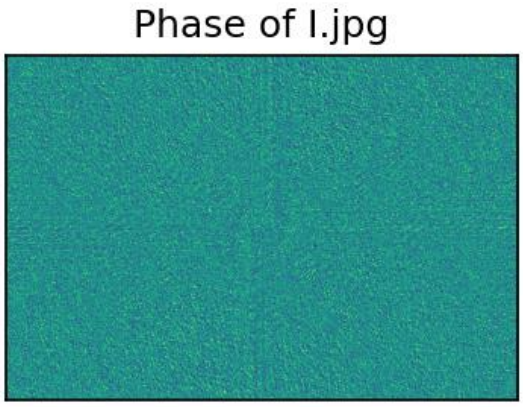

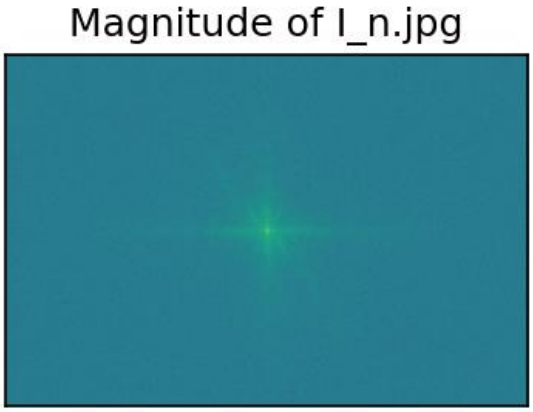

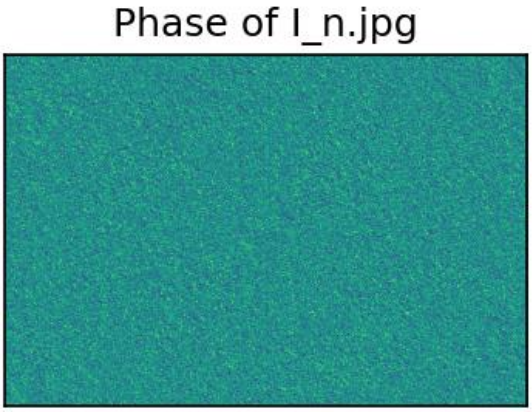

ניתן לראות כי עוצמת התדרים הגבוהים בתמונה ללא הרעש יותר מדויקת ופחות מפוזרת מהתמונה עם הרעש, כלומר הרעש מפזר על פני כל התדרים.

b. החסרנו בין האמפליטודות של התמונות, וקיבלנו את הערך המוחלט של ההפרש בין התמונות

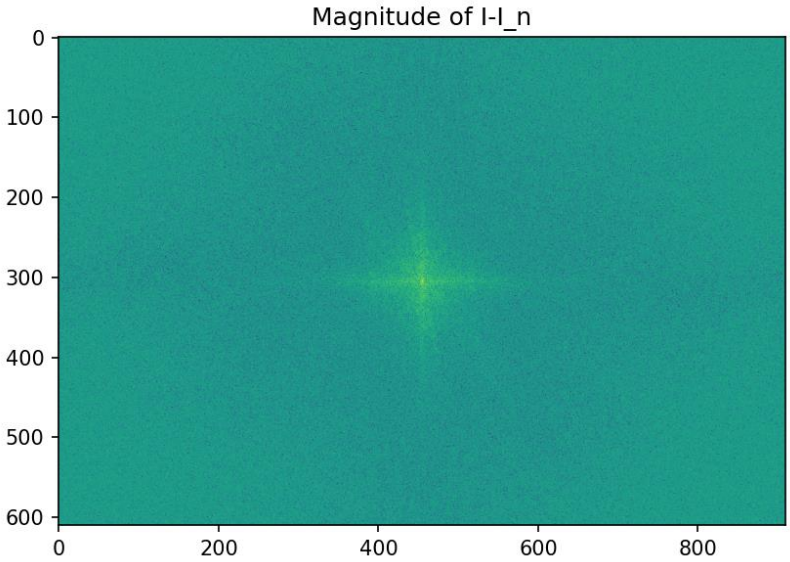

ניתן לראות שהפחתה שלהם יוצרת בערך מוחלט פיזור של הרעש שוב על פני כל התדרים והקטנת עוצמת התדרים הנמוכים המשותפים לשתי התמונות.

c. בסעיף זה נדרשנו לחשב ולהציג את אמפליטודת התמרת הפורייה של הצ'יטה ואת הפאזה של התמרת הפורייה של הזברה:

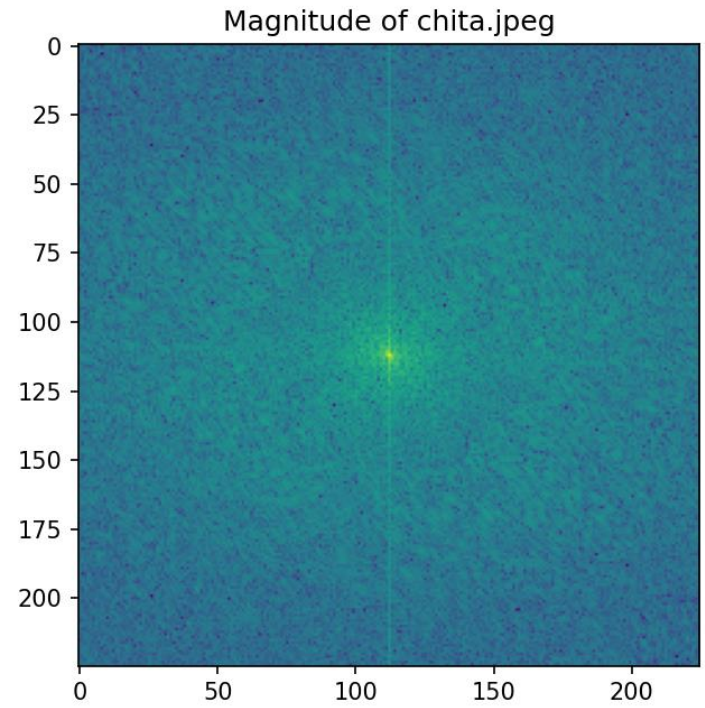

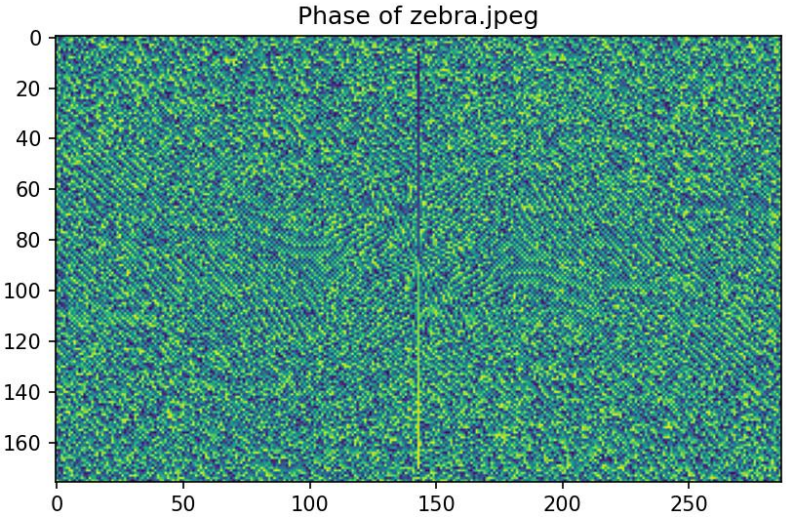

d. בסעיף זה שחזרנו מהאמפליטודה של הצ'יטה ומהפאזה של הזברה תמונה חדשה:

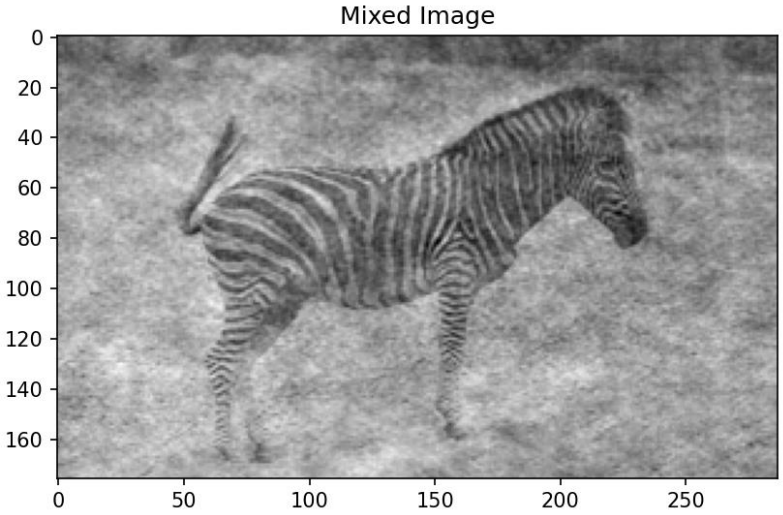

נדרשנו לשנות את הגודל של תמונת הצ'יטה כך שיתאם לתמונת הזברה כך שיהיו באותו הגודל ונוכל לעשות את ההתמרה ההפוכה.

כפי שלמדנו בהרצאה ניתן לראות שעיקר המידע נמצא באזור הפאזה, לכן שילוב של פאזת הזברה ואמפליטודת הצ'יטה יוצר זברה.

נספח 1- הקוד המלא לחלק 1:

```
import numpy as np
import cv2
from matplotlib import pyplot as plt


def interpolation(img):  # 1.a
    """ This function does super resolution by bilinear interpolation
        img: 2D numpy array of the original image (n*m)
        return: 2D numpy array of the new image (2n*2m)"""
    h, w = img.shape
    new_h, new_w = h * 2, w * 2
    new_img = np.zeros((new_h, new_w))

    # Iterate over every pixel in the new image
    for i in range(new_h):
        for j in range(new_w):
            # Find the coordinates in the original image
            x = i / 2
            y = j / 2

            # Get the coordinates of the surrounding pixels
            x0 = int(np.floor(x))
            y0 = int(np.floor(y))
            x1 = min(x0 + 1, h - 1)
            y1 = min(y0 + 1, w - 1)

            # Calculate the differences
            dx0 = x - x0
            dx1 = x1 - x
            dy0 = y - y0
            dy1 = y1 - y

            # Get the pixel values
            top_left = img[x0, y0]
            top_right = img[x0, y1]
            bottom_left = img[x1, y0]
            bottom_right = img[x1, y1]

            if x0 == x1 and y0 == y1:
                new_img[i, j] = top_left  # no need to interpolate - take
original pixel
                continue
            if x0 == x1:
                new_img[i, j] = top_left * dy1 + top_right * dy0  #
interpolate only in the y direction
                continue
            if y0 == y1:
                new_img[i, j] = top_left * dx1 + bottom_left * dx0  #
interpolate only in the x direction
                continue
            top = top_left * dy1 + top_right * dy0  # interpolate in the y
direction
            bottom = bottom_left * dy1 + bottom_right * dy0
            new_img[i, j] = top * dx1 + bottom * dx0  # interpolate in the
x direction
    return new_img
```

```
def plot_hist(img, title='Image Histogram'):
    hist, bins = np.histogram(img.flatten(), 256, [0, 256])
    plt.plot(hist, color='gray')
    plt.xlim([0, 256])
    plt.xlabel('Intensity')
    plt.ylabel('Number of pixels')
    plt.title(title)
    plt.savefig('./' + title + '.jpg')  # Save the histogram - optional
    plt.show()


def stretch_contrast(img, title='Stretched Image'):
    """
    This function stretches the contrast of the image - for each pixel
value, the new value is calculated by:
    new_value = (value - min_value) * 255 / (max_value - min_value)
    :param img: 2D numpy array of the original image
    :param title: title of the plot
    :return: stretched image
    """
    min_value = np.min(img)
    max_value = np.max(img)
    new_img = np.round(((img - min_value) / (max_value - min_value)) *
255).astype(np.uint8)
    # Plot the new image and its histogram
    plt.imshow(new_img, cmap='gray')
    plt.title(title)
    cv2.imwrite('./' + title + '.jpg', new_img)  # Save the image -
optional
    plt.show()
    return new_img


def equalize_hist(img, title='Equalized Image'):
    """
    This function equalizes the histogram of the image
    :param img: 2D numpy array of the original image
    :param title: title of the plot
    :return: equalized image
    """
    hist, bins = np.histogram(img.flatten(), 256, [0, 256])
    cdf = hist.cumsum()
    cdf_normalized = cdf / cdf.max()  # Normalize the CDF to [0, 1]
    new_img = np.round(cdf_normalized[img] * 255).astype(np.uint8)  # Map
the original image using the normalized CDF

    # Plot the new image and its histogram
    plt.imshow(new_img, cmap='gray')
    plt.title(title)
    cv2.imwrite('./' + title + '.jpg', new_img)  # Save the image -
optional
    plt.show()
    return new_img


if __name__ == '__main__':  # Part A
    # 1.Interpolation:
    # 1.b
    print('Loading peppers image')
    peppers = cv2.imread('./peppers.jpg', 0)
    print('Interpolating peppers image by 2')
```

```
    peppers_interp_by_2 = interpolation(peppers)
    print('Saving interpolated peppers image (by 2)')
    cv2.imwrite('./Peppers_interpolated_by_2.jpg', peppers_interp_by_2)
    # 1.c
    print('Interpolating peppers image by 8 ')  # 2 times interpolation by
2(to already interpolated by 2 image)
    peppers_interp_by_8 = interpolation(interpolation(peppers_interp_by_2))
    print('Saving interpolated peppers image (by 8)')
    cv2.imwrite('./Peppers_interpolated_by_8.jpg', peppers_interp_by_8)

    # 2.Equal Histogram:
    print('Loading leaf image')
    leaf = cv2.imread('./leafs.jpg', 0)
    # 2.a
    print('Calculating and plotting the histogram of the leaf image by the
pixels values (0-255)')
    plot_hist(leaf, 'Leafs Histogram')
    # 2.b
    print('Stretching contrast of the leaf image')
    strech_leaf = stretch_contrast(leaf, 'Stretched Leafs')
    plot_hist(strech_leaf, 'Stretched Leafs Histogram')
    # 2.c
    print('Equalizing the histogram of the leaf image')
    equalize_leaf = equalize_hist(leaf, 'Equalized Leafs')
    plot_hist(equalize_leaf, 'Equalized Leafs Histogram')
    print('Done')
```

נספח 2 – הקוד המלא לחלק 2:

```
import numpy as np
import cv2
from matplotlib import pyplot as plt
from scipy import ndimage, fftpack


def conv2d(img, kernel):
    """
    This function performs 2D convolution between an image and a kernel
    :param: img: 2D numpy array of the original image.
    :param: kernel: 2D numpy array of the kernel, size k*k
    :return: 2D numpy array of the convolved image which in same size as
the original image using zero padding.
    """
    n, m = img.shape
    k = kernel.shape[0]
    padding_val = k // 2
    # Zero padding
    padded_img = np.zeros((n + 2 * padding_val, m + 2 * padding_val))
    padded_img[padding_val:padding_val + n, padding_val:padding_val + m] =
img
    new_img = np.zeros((n, m))
    # Iterate over every pixel in the new image and apply the kernel
    # on the surrounding pixels in the original image
    for i in range(n):
        for j in range(m):
            new_img[i, j] = np.sum(padded_img[i:i + k, j:j + k] * kernel)
    return new_img


def directive_filter(img):
    """
    This function applies the directive filter on the image instead of
using the kernel 1*3 and write more code,
    we will use the following kernel which is 3*3 and will give the same
result.
    :param: img: 2D numpy array of the original image
    :return: 2D numpy array of the filtered image
    """
    kernel = np.array([[0, 0, 0], [-1, 0, 1], [0, 0, 0]])
    return conv2d(img, kernel)


def gaussian_filter(img, sigma=1):
    """
    This function applies the gaussian filter on the image
    :param: img: 2D numpy array of the original image
    :return: 2D numpy array of the filtered image
    """
    return ndimage.gaussian_filter(img, sigma)


def sobel_filter(img):
    """
    This function applies the horizontal sobel filter on the image as
learned in the lecture
    :param: img: 2D numpy array of the original image
    :return: 2D numpy array of the filtered image
    """
```

```
    kernel_x = np.array([[1, 0, -1], [2, 0, -2], [1, 0, -1]])
    grad_x = conv2d(img, kernel_x)
    return grad_x


def fft(img):
    """
    This function applies the FFT on the image
    :param: img: 2D numpy array of the original image
    :return: 2D numpy array of the filtered image
    """
    return fftpack.fftshift(fftpack.fft2(img))


def ifft(fft_img):
    """
    This function applies the inverse FFT on the image
    :param: fft_img: 2D numpy array of the FFT image
    :return: 2D numpy array of the filtered image
    """
    return fftpack.ifft2(fftpack.ifftshift(fft_img)).real


def display_mag_phase(fft_img, title='FFT'):
    """
    This function displays the magnitude and the phase of the FFT
    :param: fft_img: 2D numpy array of the FFT image
    :param: title: string of the title of the image
    """
    plt.figure()
    plt.subplot(121), plt.imshow(np.log(1 + np.abs(fft_img)))  # Log
scaling for better visualization
    plt.title(f'Magnitude of {title}'), plt.xticks([]), plt.yticks([])
    plt.subplot(122), plt.imshow(np.angle(fft_img))
    plt.title(f'Phase of {title}'), plt.xticks([]), plt.yticks([])
    plt.savefig(f'./fft_{title}.jpg')  # Save the image - optional
    plt.show()


def display_mag(fft_img, title='FFT'):
    """
    This function displays the magnitude of the FFT
    :param: fft_img: 2D numpy array of the FFT image
    :param: title: string of the title of the image
    """
    plt.imshow(np.log(1 + np.abs(fft_img)))
    plt.title(f'Magnitude of {title}')
    plt.savefig(f'./Magnitude_{title}.jpg')  # Save the image - optional
    plt.show()


def display_phase(fft_img, title='FFT'):
    """
    This function displays the phase of the FFT
    :param: fft_img: 2D numpy array of the FFT image
    :param: title: string of the title of the image
    """
    plt.imshow(np.angle(fft_img))
    plt.title(f'Phase of {title}')
    plt.savefig(f'./phase_{title}.jpg')  # Save the image - optional
    plt.show()
```

```python
def main():
    print("Loading image I.jpg")
    img_I = cv2.imread('./I.jpg', 0)

    print("Loading image I_n.jpg")
    img_I_n = cv2.imread('./I_n.jpg', 0)

    # Apply clipping filter on both images
    directive_img_I = directive_filter(img_I)
    directive_img_I_n = directive_filter(img_I_n)

    # Display the images
    cv2.imshow('Directive Filter on I.jpg', directive_img_I)
    cv2.imshow('Directive Filter on I_n.jpg', directive_img_I_n)
    cv2.waitKey(0)
    print("Saving images after applying the directive filter")
    cv2.imwrite('./directive_img_I.jpg', directive_img_I)
    cv2.imwrite('./directive_img_I_n.jpg', directive_img_I_n)

    # Apply Gaussian filter on I_n.jpg
    gaussian_img = gaussian_filter(img_I_n, 2)
    # Save the image
    print("Saving image after applying the gaussian filter")
    cv2.imwrite('./I_dn.jpg', gaussian_img)
    # Display the image
    cv2.imshow('Gaussian Filter on I_n.jpg', gaussian_img)
    cv2.waitKey(0)

    # Apply Sobel filter on I_n.jpg
    sobel_img = sobel_filter(img_I_n)
    # Save the image
    print("Saving image after applying the sobel filter")
    cv2.imwrite('./I_dn2.jpg', sobel_img)
    # Display the image
    cv2.imshow('Sobel Filter on I_n.jpg', sobel_img)
    cv2.waitKey(0)

    # 3a calculate the FFT of I.jpg and I_n.jpg and display the magnitude
and the phase
    fft_img_I = fft(img_I)
    fft_img_I_n = fft(img_I_n)
    # Display the magnitude and the phase of the FFT
    print("Displaying the magnitude and the phase of the FFT")
    display_mag_phase(fft_img_I, 'I.jpg')
    display_mag_phase(fft_img_I_n, 'I_n.jpg')

    # 3b subtract the magnitude of the FFT of I_n.jpg from the magnitude of
the FFT of I.jpg
    # and display the magnitude of the result
    print("Subtracting the magnitude of the FFT of I_n.jpg from the
magnitude of the FFT of I.jpg")
    fft_img_diff = np.abs(np.abs(fft_img_I) - np.abs(fft_img_I_n))
    display_mag(fft_img_diff, 'I-I_n')

    # 3c magnitude of chita.jpg and phase of zebra.jpg
    img_chita = cv2.imread('./chita.jpeg', 0)
    img_zebra = cv2.imread('./zebra.jpeg', 0)
    print("Displaying the magnitude of chita.jpeg and the phase of
zebra.jpeg")
```

```
    fft_img_chita = fft(img_chita)
    fft_img_zebra = fft(img_zebra)
    display_mag(fft_img_chita, 'chita.jpeg')
    display_phase(fft_img_zebra, 'zebra.jpeg')

    # 3d calculate the inverse FFT of magnitude of chita.jpg and phase of
zebra.jpg
    # and display the result
    # Resize the images to have the same dimensions
    img_chita = cv2.resize(img_chita, (img_zebra.shape[1],
img_zebra.shape[0]))
    print("Calculating the inverse FFT of magnitude of chita.jpg and phase
of zebra.jpg as mixed image")
    fft_img_chita = fft(img_chita)
    fft_mixed_img = np.abs(fft_img_chita) * np.exp(1j *
np.angle(fft_img_zebra))
    mixed_img = ifft(fft_mixed_img)
    plt.imshow(mixed_img, cmap='gray')
    plt.title('Mixed Image')
    plt.show()
    cv2.imwrite('./mixed_img.jpg', mixed_img)
    print("Done")


if __name__ == '__main__':
    main()
```